

Redes neuronales artificiales para el procesamiento de imágenes, una revisión de la última década

Ramírez Q. Juan A. y Chacón M. Mario I.

Artificial neural networks for image processing, a review of the last decade

Abstract— The widespread use of Artificial Neural Networks in the image processing field motivated a review of 200 papers. This review documents the use of neural network architectures for classification, recognition and segmentation in digital images. The present review describes different neural networks architectures as well as some of their modifications and applications on image processing. Then new neural networks models including spiking neurons are covered. An analysis of the literature reviewed organized by the type of image processing achieved by the neurons is described and finally the conclusion of this work are commented.

Keywords— Artificial Neural networks, Image Processing, Computational Intelligent.

Resumen— El amplio uso de las redes neuronales en el campo del procesamiento de imágenes, motiva a realizar una revisión de 200 artículos donde se documentan algoritmos que utilizan alguna arquitectura de redes neuronales para tareas de clasificación, reconocimiento o segmentación en imágenes digitales. Esta revisión presenta los distintos modelos de redes así como sus modificaciones y aplicaciones en el procesamiento de imágenes. Luego se documentan algunos aspectos de nuevas redes neuronales incluyendo los modelos pulsantes, se presenta el análisis de los trabajos revisados organizado por el tipo de procesamiento que hacen las redes neuronales y finalmente se comentan las conclusiones del estudio realizado.

Palabras clave— Redes Neuronales Artificiales, Procesamiento de Imágenes, Computación Inteligente.

I. INTRODUCCIÓN

Durante las décadas pasadas, surgieron modelos de redes neuronales artificiales (RNA) postuladas de diversas teorías del funcionamiento de redes neuronales biológicas. Desde entonces, han sido numerosos los trabajos propuestos donde se aplican RNAs en diferentes áreas de la ingeniería. Un área donde se utilizan ampliamente dichas redes es la de procesamiento de imágenes, donde existe una gran cantidad de trabajos propuestos con RNAs. Esto ha motivado diversas revisiones acerca de la contribución de dichos trabajos. En 2002 Egmont-Petersen

Manuscrito recibido el 9 de junio de 2011. Este trabajo fue financiado por el Fondo Mixto de Fomento a la Investigación Científica y Tecnológica CONACYT- Gobierno del Estado de Chihuahua, bajo el apoyo CHIH-2009-C02-125358.

J.A. Ramírez y M.I. Chacón son miembros del Laboratorio de Percepción Visual con aplicaciones en Robótica en el Instituto Tecnológico de Chihuahua, Ave. Tecnológico 2909, Chihuahua Chih., C.P. 31310 México. Teléfono: +(52) 614-413-7474; fax: +(52) 614-413-5187. e-mail: jaramirez@itchihuahua.edu.mx, mchacon@ieec.org




Fig. 1. Niveles de procesamiento.

realizó una revisión de 200 artículos de redes neuronales aplicadas al área de procesamiento de imágenes publicados en la década de los noventa. El enfoque presentado fue en los distintos tipos de redes *feedforward*, aunque hace referencia a redes como la red de Kohonen (SOM), Hopfield, Red neuronal celular (CNN), memorias asociativas y redes ART y su contribución en procesamiento de imágenes [1]. Misra en 2010 realizó un estudio de las implementaciones en hardware de las RNAs en las últimas dos décadas [2]. Wang, Ma y Cheng en 2010 publican una revisión de trabajos relacionados con la red pulso-acoplada (PCNN) y su aplicación en la solución de problemas del área de procesamiento de imágenes [3]. Otros estudios de RNAs se enfocan a distintas aplicaciones como sistemas financieros, técnicas biométricas, criptosistemas, control automático, etc [4][5][6]. Con respecto a otras técnicas de computación inteligentes y procesamiento de imágenes, Naz en 2010 hace un estudio de las técnicas de segmentación en imágenes digitales con agrupamiento difuso con probabilidad espacial y *Fuzzy C Means* (FCM) para procesamiento de imágenes [7]. Senthilkumaran hace un resumen en 2009 donde documenta varios tipos de algoritmos para segmentar imágenes con técnicas de lógica difusa, algoritmos genéticos y la SOM[8].

Sin embargo, en la literatura analizada, no se reportan revisiones de las distintas redes neuronales aplicadas a procesamiento de imágenes de los últimos años. Por lo tanto, en este trabajo se presenta una revisión de 200 trabajos publicados en los últimos diez años enfocándose a documentar las distintas modificaciones que han tenido las diferentes arquitecturas de redes neuronales para mejorar su aplicación en procesamiento de imágenes. De estos trabajos, 167 documentan RNAs y procesamiento de imágenes, 18 trabajos tratan sobre nuevos modelos de redes pulsantes y 15 son análisis de redes neuronales y procesamiento de imágenes. Debido a restricciones de espacio solo se documentan 77 de estas referencias. Los artículos revisados, fueron seleccionados de varios trabajos con base al prestigio de la revista o congreso que publica, el impacto que tiene la publicación en la contribución al procesamiento de imágenes y a la aplicación dirigida.

La organización del artículo es la siguiente. En la Sección II se da una introducción a la taxonomía de los niveles del procesamiento de imágenes. En la Sección III se estudian las RNAs aplicadas a procesamiento imágenes y sus modificaciones,

en la Sección IV se documentan los resultados y en la Sección V las conclusiones.

II. TAXONOMÍA DEL PROCESAMIENTO DE IMÁGENES

Las técnicas para analizar una imagen digital se agrupan en un área llamada Procesamiento Digital de Imágenes. Estas herramientas se organizan según el nivel de procesamiento que se desea realizar para analizar la información contenida en una imagen digital. Estos niveles forman una cadena de procesamiento como la que se ve en la figura 1[1]. A continuación se describen brevemente:

- 1) *Pre-procesamiento*. Operaciones para adaptar la información de una imagen y tener mejor análisis en pasos posteriores. Ejemplos de procesamiento son las operaciones de brillo y contraste.
- 2) *Segmentación*. Operaciones para hacer una partición de la imagen en varias regiones que representen la información necesaria para el problema a resolver.
- 3) *Detección de objetos y clasificación*. Determinación y clasificación de los objetos contenidos en la imagen.
- 4) *Análisis de imagen*. Obtener información de alto nivel acerca de lo que la imagen muestra.

Por su potencial para reconocer patrones de información las RNA han sido desde hace décadas herramientas para resolver problemas en cualquiera de los niveles del procesamiento de imágenes. Esto debido a que las imágenes digitales contienen mucha información difícil de interpretar por una máquina. En la literatura analizada, la mayoría de las aplicaciones de las RNAs en imágenes digitales fueron para tareas de segmentación y clasificación (CL). Para desglosar la información, la parte de segmentación se separó de la siguiente manera:

- 1) *Segmentación de forma (SS)*. Se refiere a generar una nueva imagen binarizada donde el resultado son regiones representativas de la información que se desea analizar.
- 2) *Detección de bordes (CS)*. Extracción de altas frecuencias en la imagen que representen contornos y límites de objetos en la imagen.
- 3) *Segmentación de color (CrS)*. Partición de la imagen en regiones que agrupan colores similares.
- 4) *Segmentación de Textura (TS)*. Partición de una imagen con base a los patrones de variación espacial de las intensidades de grises y color.
- 5) *Segmentación de movimiento (VS)*. Detección de objetos dinámicos en una secuencia de imágenes.

También se reportaron trabajos para eliminación de ruido (NR), agrupamiento de datos para aplicaciones específicas (Ct) y comparación entre RNAs (VR).

III. REDES NEURONALES Y PROCESAMIENTO DE IMÁGENES

A. Breve historia de las RNAs

El sistema nervioso de los animales se estructura con neuronas que forman redes para el procesamiento de información generada por los diversos estímulos de entrada de los sistemas sensoriales. Dichas redes, han servido también de inspiración




Fig. 2. Modelo de neurona artificial con salida binaria[9].

para modelar las redes neuronales artificiales (RNA), las cuales son interconexiones de neuronas artificiales. Estas redes surgieron a partir de las ideas en la publicación de McCulloch y Pitts, donde se postula que las neuronas funcionan como dispositivos booleanos. Este postulado fue criticado como teoría biológica, pero permitió generar una neurona como un modelo lineal seguido de una función activación booleana. Aquí, la función lineal representa la sinapsis (unión entre neuronas) y la agregación de la información, mientras que la función no lineal representa el procesamiento que hace la neurona. Esto resultó en un modelo que se ilustra en la figura 2, donde la función lineal se ve en la ecuación (1).

$$r = \sum_{i=1}^n x_i w_i + b \quad (1)$$

Aquí, x_i son los datos de entrada, w_i son los pesos sinápticos y b un factor de polarización. El resultado de r , es procesado por una función binaria que da un uno o un cero a la salida según el valor de r [10].

El perceptrón fue el primer modelo de red neuronal, el cual utiliza la neurona artificial de la figura 2, además de que tenía su arquitectura en tres capas y un algoritmo de aprendizaje. Este fue probado como un detector de caracteres ópticos, por lo que el campo de redes neuronales se inició como una forma de procesar imágenes [10].

Luego del perceptrón y otras redes con neuronas binarias, surgen otros modelos que también han sido utilizados en el área de procesamiento de imágenes. Como las redes con funciones de activación continuas, tales como las sigmoideas o las funciones de base radial, definidas en las ecuaciones (2) y (3) respectivamente.

$$f(r) = \frac{1}{1 + \exp(-\alpha r)} \quad (2)$$

$$f(x, c) = f(\|x - c\|) \quad (3)$$

Donde α es un parámetro que caracteriza la inclinación de la función, c es un punto llamado centro. En la figura 3 se observan ejemplos de las funciones sigmoidea y radial con respecto a la agregación r . En general, los modelos clásicos de estas redes tienen la característica de ser supervisados, es decir, necesitan una referencia en un proceso de entrenamiento para obtener una salida deseada a una entrada determinada. También se han generado modelos con características no supervisadas como los mapas auto-organizados de Kohonen (SOM) y la Teoría de Resonancia Adaptiva (ART). Además han surgido otros modelos como las Redes Neuronales Recurrentes, y las que se basan en




Fig. 3. (a) Función sigmoideal. (b) Función de base radial.

modelos probabilísticos que han sido por varios años muy útiles en el área del procesamiento de imágenes [1].

En los últimos 10 años, han sido varias las arquitecturas de redes neuronales utilizadas para procesamiento de imágenes. De la literatura analizada se reportan trabajos relacionados a procesamiento de imágenes con la teoría de resonancia adaptiva (ART), red neuronal celular (CNN), perceptrón multicapa (MLP), redes neuronales oscilatorias (ONN), red neuronal pulsoacoplada (PCNN), redes neuronales recurrentes (RNN), redes neuronales basadas en modelos probabilísticos (RPNN), red neuronal de funciones radiales (RBFNN) y los mapas auto-organizados de kohonen (SOM). A continuación se presentan estos casos.

B. Teoría de Resonancia adaptiva (ART)

Es un modelo de red neuronal artificial que basa su funcionamiento en la forma en cómo el cerebro procesa información [11][12]. Esta arquitectura puede ser supervisada y no supervisada. Dicha red se basa en el dilema plasticidad-estabilidad del aprendizaje y se implementa en tres arquitecturas, la ART1 para entradas binarias, ART2 para valores continuos y escalas de grises y ARTMAP que combina ART1 y ART2 formando una estructura de aprendizaje supervisado. La forma básica de ART es un modulo de comparación, un parámetro de vigilancia y un modulo de reinicio. El modulo de comparación toma un vector de entrada y lo agrupa en alguna clase conocida por la red. El parámetro de vigilancia se encarga de indicar el grado de pertenencia de la entrada a alguna clase dada. Si la entrada no pertenece a ninguna clase, se crea una clase nueva. Esta red es muy útil por su capacidad para agrupar datos según su información, siendo una técnica de reconocimiento de patrones.

En la búsqueda de artículos relacionados con el modelo ART, se observó que ART1 se ha utilizado para reconocimiento de huellas digitales y de caracteres. Mientras que ART2 y ARTMAP se utilizan como clasificadores de patrones o para agrupamiento de datos en distintas aplicaciones. ARTMAP apareció en todos los trabajos en su modelo difuso *Fuzzy ARTMAP* (FAM). Dentro de las modificaciones de ART, se encontró una utilizada por Liu quien publica ART MMAP (ART Mixture MAP), la cual consiste en una red neuronal ART basada en un *mixture model* (modelo de mezcla estadística) para la clasificación de subpíxeles de regiones en imágenes satelitales[13]. Poh Tan presenta en [14] un modelo de ARTMAP modular (MARTMAP), la cual es una variación de ARTMAP enfocada al reconocimiento de patrones multiclases por medio de módulos. *Simplified FAM* (SFAM) es una variante de ART

simplificada en dos capas una de entrada y otra de salida y se utiliza en reconocimiento de caracteres en [15].

C. Red Neuronal Celular (CNN)

Basada en la teoría de los autómatas celulares, esta red permite la interacción de los vecinos de cada unidad en la red. Contiene una cantidad fija de unidades llamadas células, las cuales son sistemas no lineales, dinámicos donde la información de entrada es codificada para conocer su comportamiento. Cada célula está localmente interconectada con múltiples entradas que vienen de otras células. La dinámica puede ser continua (CT-CNN) ó discreta (DT-CNN).

Con respecto a la CNN, la mayoría de los trabajos revisados se enfocan a detección de bordes, segmentación de formas y algunos trabajos en detección de movimiento. En [16], Kawahara utiliza una CNN con plantilla dinámica (DCNN) que actualiza ciertos valores de aprendizaje en iteraciones y se utilizó para detección de movimiento. Strzelecki hace un método de segmentación de texturas en [17] basado en una red de oscilaciones sincronizadas con la CNN (SON) y al comparar el método con la clásica MLP obtuvo un mejor desempeño. En [18], Babatunde modifica el modelo de la CNN para mejorar la detección de bordes con respecto a otros métodos como *canny*. Kang en 2009 propone un algoritmo para segmentación de huella digital utilizando lógica difusa para obtener un umbral y a partir de ahí se utiliza una *Threshold CNN* (TCNN) para agrupar píxeles [19]. Corinto presenta una modificación de la CNN basado en aproximaciones polinomiales (PoCNN) probada en segmentación de regiones y se prueba su comportamiento dinámico [20]. En 2006 se desarrolló una arquitectura de CNN difuso (FCNN) para obtener segmentación de forma y bordes [21]. Una variante interesante es la DTCNN (CNN de tiempo discreto), la cual se vio en trabajos enfocados a segmentación de bordes [22]. Un aspecto interesante de la CNN además de sus variantes, es que es muy propicia para implementaciones en hardware. Por lo cual fue común encontrar diversas implementaciones de algoritmos CNN en *chips* o en GPUs (Unidades de procesamiento gráfico)[22][23]. Otro aspecto es que la CNN mostró en esta búsqueda es la capacidad en detección de bordes, ya que tal como en [18], fue común que los resultados con métodos clásicos de procesamiento de imágenes fueran comparados con la CNN en diversos trabajos, teniendo siempre una mayor capacidad para delimitar contornos con poca cantidad de ruido.

D. Perceptrón multicapa (MLP) y Backpropagation (BP)

Esta parte se refiere a redes perceptrón multicapa con funciones de activación sigmoideas que son entrenadas mediante algoritmos de aprendizaje BP. Debido a que MLP fue de los primeros modelos de redes neuronales, se plantean en muchos trabajos para comparar el desempeño entre un modelo propuesto y un perceptrón o un algoritmo de entrenamiento con BP. Otros autores como Narasimha han utilizado MLP para validar el desarrollo de algoritmos de optimización de RNAs[24].

De los resultados de las búsquedas, Crespo hace una modificación donde propone una MLP con función de activación sigmoideal y pesos como funciones gaussianas entrenados con una

variante de BP para ajuste de pesos gaussianos y tuvo buen desempeño en imágenes multispectrales[25]. Shiblee sugiere una variante de red con activación sigmoideal pero las agregaciones de los vectores de pesos y entradas, se basan en el algoritmo de la media ponderada generalizada (GMP) [26]. Rajini en 2010 publica una evaluación del desempeño de algoritmos de entrenamiento de redes neuronales para reconocimiento de objetos. Para ellos, se utilizaron diferentes algoritmos de entrenamiento basados en BP. Las variaciones estudiadas son *BPmom* (variación de *momentum*), *Through Time*, *Resilen* y *Quick*. De estos, el algoritmo que logró converger más rápido fue el *BPmom*. Para probar los algoritmos se utilizaron varias imágenes [27]. El resto de los trabajos estudiados, se enfocan en aplicaciones de clasificación donde se auxilia la red de técnicas como transformada de *Hough*, FCM y Transformada del coseno.

E. Red Neuronal Oscilatoria (ONN)

La teoría de las redes oscilatorias se basa en los estímulos con oscilaciones periódicas sincronizadas en forma de grupos en la corteza visual y es posible que sirvan para detectar características en una escena visual. A partir de esto, se modelan redes con características oscilatorias que se van sincronizando según el patrón de entrada.

En la literatura se reportaron diferentes ejemplos de redes oscilatorias, pero lo más común fue el modelo LEGION (*locally excitatory globally inhibitory oscillator network*) en el cual la oscilación se genera a partir de la retroalimentación de un vecindario de unidades excitables y un inhibidor global. Aquí cada unidad excitable es estimulada de forma proporcional a cada entrada formando una retroalimentación con el inhibidor y se crea una oscilación cuya forma depende del estímulo de entrada. De esta manera, se va generando una serie de oscilaciones que representan cada patrón de formas que tiene una imagen [28].

De esta red se revisaron algunos trabajos, todos enfocados a segmentación de objetos y texturas. También fue común encontrar implementaciones en hardware con las redes oscilatorias. Fernández implementa el modelo LEGION en un FPGA en [29] para segmentación de carácter e implementa el mismo modelo en un circuito CMOS [30].

F. Red Neuronal Pulso-Acoplada (PCNN)

Esta red es utilizada para preprocesamiento y desarrollada por Eckhorn, a partir de la corteza visual del cerebro del gato. La PCNN se implementa en un modelo de una neurona por píxel y su arquitectura tiene tres módulos principales: el módulo dendritas, el módulo de encadenamiento y el generador de pulsos. En el árbol de dendritas recibe la información del vecindario y se procesa en el módulo de encadenamiento y el *feeding*, otra parte de la red que también contiene la entrada. El generador de pulsos tiene un umbral dinámico que se basa en el proceso interno que tiene la neurona en el *feeding* y el módulo de encadenamiento [3].

Wang en 2010 publica un repaso de la PCNN donde se hace una investigación del uso de este modelo en 10 años, y se documentan modificaciones que se han publicado para

simplificar el modelo en función de mejorar el tiempo de cómputo o ampliar las aplicaciones que puede tener la PCNN. Dentro de los modelos que se reportan, está la red de Kinser que se le conoce como *intersecting cortical model* (ICM), se trata de una PCNN simplificada con menos ecuaciones y diseñada específicamente para procesamiento de imágenes. Un modelo distinto es la PCNN con encadenamiento unitario (*unit linking*), que se hace a partir de la reducción de parámetros en la neurona y haciendo la parte del encadenamiento como una sola unidad de entrada. Otro es la PCNN multispectral y se trata de una PCNN multicanal que consiste en un conjunto de PCNNs en paralelo de canales separados. En el trabajo de revisión de Wang también se hace referencia a la contribución que tienen los modelos de la PCNN en áreas del procesamiento de imágenes como segmentación, eliminación de ruido, detección de objetos y extracción de características debido su capacidad de preprocesamiento [3].

G. Redes neuronales Recurrentes (RNN)

Son redes neuronales que tienen conexiones formando un ciclo directo. Esto permite comportamientos dinámicos pero consumen más memoria que las redes directas. Los ejemplos clásicos de las redes recurrentes son las redes de *Hopfield*, la RNN bidireccional o la RNN de tiempo continuo. El uso de las RNN es muy variado tanto en procesamiento como en aplicación y tiene un gran potencial en agrupamiento de datos como ART.

De los artículos revisados con la RNN, la mayoría se enfoca a segmentación de formas y movimiento. Aunque también se dieron algunos modelos de clasificación y agrupamiento de datos. Chatterjee en [31] propone el uso de una RNN de Elman y Jordan para generar escalas de grises en imágenes de medio tono. Zheng propone en [32] una capa de modo competitivo con una Lotka Volterra RNN para extraer y segmentar objetos en imágenes digitales. Zhou plantea un modo competitivo similar a Zheg pero es una RNN con neuronas de tiempo discreto para segmentar imágenes médicas [33]. Guanzhong sugiere una RNN de ciclo dinámico (DCRNN) basada en la red de Elman para segmentación de texturas [34]. Nishide propone una RNN con parámetro de polarización (RNNBP) para extraer objetos dinámicos basados en la perspectiva del sensado activo de un robot [35]. Bianchini desarrolla un algoritmo de localización de objetos donde una RNN de entrada-salida (IO RNN) se usa para procesar gráficas posicionales acíclicas y generar funciones en espacios euclidianos [36]. Reiter en [37] hace un modelo de segmentación y reconocimiento de movimiento con una red de neuronas para memorias recurrentes (LSTM RNN) y cadenas de Markov. En la literatura revisada solo se encontró un trabajo relacionado con la red original de Hopfield, propuesto por Morikawu para reducción de ruido [38].

H. Red Neuronal con Funciones de Base Radial (RBFNN)

Las RBFNN son redes que contienen funciones de activación de base radial que cumplen con el criterio que se ve en la ecuación (3). Generalmente estas funciones de activación son de tipo gaussiano. Las RBFNN, consisten típicamente de una red de tres capas; la de entrada, la oculta que contiene funciones de base radial no lineal y la capa de salida. Las RBFNN son muy

utilizadas en aplicaciones específicas como segmentación de tejidos en imágenes médicas, inspección de calidad en procesos industriales, reconocimiento de rostros y gestos.

De los artículos revisados que documentan procesamiento de imágenes con RBFNN, la mitad se enfocan a trabajos de clasificación, el resto utilizan la RBFNN principalmente para segmentación de formas. Veera hace una comparación en el funcionamiento de una RBFNN y una MLP para tareas de categorización y recuperación de datos [39]. Kumar en [40] utiliza una RBFNN para reducir tiempos de computación en algoritmos de segmentación de formas basado en agrupamiento difuso para imágenes médicas. Sing desarrolló un algoritmo de segmentación de imágenes del cerebro donde utilizó una RBFNN autoadaptiva que emplea una función para hacer un espacio de características separables no lineales y simular el proceso del cerebro en tratar con una situación nueva [41]. Benamrane propone el uso de una RBFNN con un algoritmo genético que calcula el número de neuronas con funciones de activación gaussianas para segmentación de imágenes para detección de bordes en imágenes médicas del cerebro [42].

1. Redes Neuronales probabilísticas (RPNN)

En la literatura analizada se encontraron tres tipos de redes probabilísticas, la red neuronal probabilística (PNN), el algoritmo de mezclas gaussianas (GMM) y la red neuronal aleatoria. La PNN es una RNA semi-supervisada basada en las redes de decisión bayesiana. La arquitectura consta de cuatro capas. La primera capa recibe el vector de entrada. La segunda capa tiene un conjunto de neuronas totalmente conectadas con las neuronas de la primera capa con funciones de activación dada por:

$$\phi_{jk}(x) = \frac{1}{(\sqrt{2\pi}\sigma)^d} \exp\left(-\frac{1}{2\sigma^2}(x - m_{jk}^x)^2\right) \quad (4)$$

Donde d es el tamaño del vector, x es la entrada, m_{jk}^x es la media del j -ésimo vector de referencia, k es la clase correspondiente y σ es un parámetro de suavizado. La tercera clase es la capa de suma que complete la estimación de probabilidad. La última capa clasifica la entrada de acuerdo a la decisión bayesiana [43]. Esta red es muy utilizada para clasificación y reconocimiento de patrones en aplicaciones específicas. Las PNN encontradas en la revisión se utilizan para segmentación de formas y texturas. Dentro de las modificaciones encontradas, está la PNN ponderada (WPNN), la cual resuelve algunas limitantes de la PNN clásica por una matriz de covarianza que reemplaza los factores de suavizado singular y agrega ponderaciones a la capa de suma. Estos factores ponderados indican la probabilidad de que un vector de referencia pertenezca a una clase. La WPNN se utilizó para segmentación de formas en imágenes del cerebro y se probó con una SOM previa al procesamiento de la red [44][45]. Otra variante presentada es la *Background Neural Network* (BNN), la cual sirve como modelo estadístico de los antecedentes de cada posición de un píxel en una secuencia de video [46]. Otro modelo de interés que se encontró fue una RNAs aleatoria, la cual se trata de una representación matemática de neuronas que intercambian señales pulsantes. Cada neurona es representada por un entero cuyo valor se incrementan cuando la célula recibe un

pulso que la inhibe ó habilita, de manera que los impulsos se asocian con 1 y -1. De los artículos revisados solo se encontró una red neuronal aleatoria, que realiza segmentación de texturas utilizando también un filtro Gabor [47].

Un algoritmo también probabilístico, es el modelo de mezclas gaussianas (GMM) y es una herramienta muy útil para agrupación en poblaciones de datos. Este método es una función de densidad de probabilidad paramétrica representada como la suma ponderada de densidades gaussianas [48]. Esta función de probabilidad es tomada como una red neuronal probabilística [49]. Es muy utilizada para clasificar patrones de voz y en segmentación de imágenes digitales. Fueron cuatro los artículos donde se utilizaba GMM, en el caso de Meur, Chevet en [50] se enfoca a hacer un algoritmo basado en la GMM para obtener la parte más sobresaliente de la imagen, mientras que Faiza en [49] y Blekas en [51] se enfocan en segmentación de texturas y en 2009 Peñalver presenta un modelo del GMM para segmentación del color con base a la entropía de datos [52].

J. Mapa Auto-Organizado de Kohonen (SOM)

La SOM es una red no supervisada que se basa en un proceso competitivo donde cada neurona en una red neuronal se vuelve sensitiva a las categorías de los patrones de entrada. Generalmente tiene una arquitectura bidimensional y utiliza el aprendizaje competitivo para que las neuronas sin una distribución de datos específica se vayan aproximando a la distribución de los datos de entrada. Esta red se ha utilizado mucho en reconocimiento de patrones para aplicaciones y en análisis de texto [53][54].

De los artículos seleccionados de la SOM, varias aplicaciones se enfocan a segmentación de formas geométricas, color, movimiento y un poco de segmentación de contornos. La SOM se encontró combinada con agrupamiento difuso, PCA y algoritmos genéticos. Un punto interesante es que se encontraron varios algoritmos que utilizan SOFM para procesar color, por ejemplo Zhang en 2007 plantea la SOFM para segmentar color donde una técnica wavelet mejora su eficiencia [55]. Christodoulou, Michaelides sugieren en [56] un algoritmo donde la técnica *K-nearest neighbor* y la SOFM agrupen píxeles que generen clases de nubes. Otra variante presentada es la SOM paramétrica (PSOM), la cual es un conjunto variado de bases no lineales para hacer mapeos topológicamente ordenados con vectores de referencia y fue utilizada por Nölker y Ritter en [57] para calcular la posición de distintos puntos a través de los ángulos entre ellos, con el objetivo de ver la posición de los dedos en una imagen digital. Wu desarrolla una variante que la denomina SASOM (SOM estructura adaptiva) y se trata de un algoritmo que encuentra el número correcto de neuronas para una aplicación, que en el caso de [58] se utiliza para reconocimiento de gestos. Otra estrategia es un método propuesto basado en mecanismos de atención visual denominado SOBS (*Self Organization Background Subtraction*), y es un algoritmo basado en diferencias de fondo pero auto-organizado para evitar ruidos en la detección de movimiento [59]. SOTM (*Self Organization Tree Map*) es otra estrategia como una SOM con características similares al modelo ART que Kyan y Jarrah presentan haciendo diversas pruebas y variantes para procesamiento de multimedia [60]. Salhi en 2009 hace una

revisión de varios modelos inspirados en la forma y la dinámica de SOM [61]. Una estrategia común fue la de combinar la SOM con otros modelos de *soft computing*, muestra de esto es la combinación realizada por Awad en [62] que combina la SOM con un algoritmo genético haciendo un sistema neurogenético. Otra combinación son los mapas auto-organizados con técnicas de lógica difusa, un ejemplo de esto es el modelo FCNN (*Fuzzy Clustering Neural Network*) el cual es un clasificador que se utilizó en agrupamiento de píxeles para segmentar movimiento [63]. La SOTFN-SV es una red difusa con inferencia Sugeno auto-organizadas para segmentación de color [64].

En estas modificaciones que fueron los modelos con mejores resultados de la SOM, se puede observar un marcado uso de la para detección de patrones de color y movimiento.

K. Redes Pulsantes (SNN)

Conforme se van generando más conocimiento en la forma en cómo funciona el sistema nervioso de los animales, nuevos modelos de RNAs surgen. Un esquema que ha tomado mucho auge en los últimos años es el de las RNAs pulsantes (SNN). Estas redes se inspiran a partir de que las células del sistema nervioso generan una serie de potenciales de acción que se pueden analizar como señales en el dominio del tiempo. En la figura 4, se puede observar que estas señales van generando una serie de picos o espigas cuya frecuencia entre pulsos y forma contiene la información necesaria para la percepción y procesamiento de la información [65].

Este esquema es muy distinto del modelo inicial de McCulloch y Pitts, ya que implica que la información que codifica una neurona va más allá de una constante binaria. Algunos autores consideran que las SNNs se pueden considerar como una tercera generación de RNAs; la primera generación son las RNAs basadas en el modelo binario de la figura 2 y la segunda generación las neuronas con funciones de activación continuas [66][67]. La mayoría de estos modelos se establecen como ecuaciones diferenciales que definen la dinámica de una neurona biológica como por ejemplo el modelo de *Hodgkin-Huxley* el cual está dado por:

$$\begin{aligned} \frac{dv}{dt} &= 0.04v^2 + 5v + 140 - u + I \\ \frac{du}{dt} &= a(bv - u) \end{aligned} \quad (5)$$

con un reinicio de espiga cuando $v \geq 30\text{mV}$, se obtiene:

$$\begin{aligned} v &\leftarrow (-65\text{mV}) \\ u &\leftarrow u + 2 \end{aligned} \quad (6)$$

donde u , v son variables dimensionales, a y b son parámetros dimensionales, t es tiempo. A partir de estas ecuaciones se diseñan neuronas pulsantes con salidas similares a las de la figura 4[68].

La teoría de neuronas pulsantes se inspira de cualquier parte del sistema nervioso, por lo que existen modelos basados en la parte del cerebro dedicada a procesar la información visual. Actualmente varios autores han propuesto distintas arquitecturas

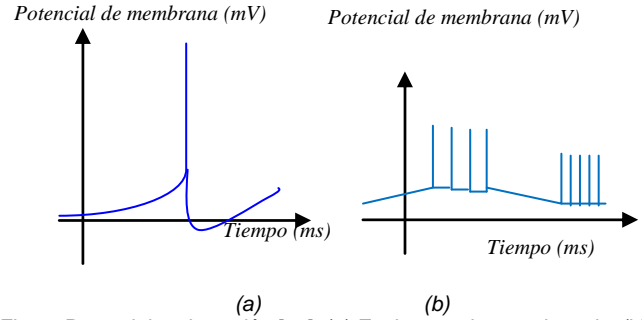


Fig. 4. Potenciales de acción [66]. (a) Espiga o pulso en sinapsis. (b) tren de pulsos (espigas) a la salida de neurona.

de SNNs, pero en la literatura analizada no se reportó un modelo más general. Sin embargo, existen algoritmos de aprendizaje como el STDP (*Spike Time Dependet Plasticity*) y en [69] se propone la Regla de Plasticidad de Actividad Sináptica (SAPR) para aprendizaje de SNNs. La SAPR se probó con neuronas pulsantes que hacen procesamiento de segmentación y clasificación en imágenes de tejidos biológicos. Otras pruebas realizadas en procesamiento de imágenes con las SNNs se ven en [70][71] donde se utilizan las SNN para detección de caracteres y líneas. En [72] se propone un modelo con SNN basado en atención selectiva y detalles sobresalientes de objetos.

L. Otras arquitecturas

También se dieron diversos casos donde las redes no se pudieron clasificar en una categoría en específico. Zhao en [73] propone una red caótica de mapas para segmentación de escenas y en [74] utiliza sistemas caóticos para agrupación de datos. Lee en 2004 utiliza oscilaciones de Lee en el modelo TCAN, (*Transient Autoassociative Network*) para segmentación de escena [75]. Shen, Chang en 2005 presenta un modelo de segmentación de imágenes del cerebro basada en agrupamiento de FCM optimizado con una RNA [76]. Lin y Chang desarrollan un modelo de RNA difusa (FNN) con inferencia de Sugeno, distribuida en cinco capas, donde la capa dos tiene las variables lingüísticas con funciones de mezclas gaussianas, la tercer capa tiene las reglas difusas y se prueba en segmentación de texturas y caracteres [77]. Rasche en [78] presenta un modelo para detección de bordes y movimiento bidimensional de neuronas pulsantes que le llama membrana excitable. Mignotte en 2011 desarrolla para segmentación no lineal de color un sistema basado en agrupamiento difuso con SVM [79]. Juang propone dos arquitecturas neurodifusas de cuatro y seis capas para clasificar posturas del cuerpo y diagnóstico de dispositivos en imágenes térmicas [80][81]. La red de cuatro etapas tiene una capa de variables lingüística, otra de inferencia y otra de salida, mientras que la de seis tiene una capa intermedia de normalización. Yang en [82] desarrolla un algoritmo para reconocimiento de gestos con una TDNN, (*Time Delay Neural Network*) la cual es una red directa que hace ventaneos de tiempo en cada capa para hacer análisis de señales en el dominio del tiempo y clasificar gestos con manos.

IV. ESTADÍSTICAS Y RESULTADOS DE LA REVISIÓN

En esta sección se presenta un concentrado de la revisión de los trabajos analizados. En la Tabla I se pueden observar las

TABLA I. TIPO DE PROCESAMIENTO REALIZADO POR LAS RNA.

| Proc./Red | ART | CNN | MLP,BP | ONN | RNN | PRNN | RBF NN | SOM | OTRAS | TOTAL |
|-----------|-----|-----|--------|-----|-----|------|--------|-----|-------|-------|
| NR | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 1 |
| TS | 0 | 2 | 0 | 1 | 1 | 4 | 0 | 1 | 1 | 10 |
| VS | 1 | 2 | 0 | 0 | 0 | 0 | 0 | 3 | 2 | 8 |
| CS | 0 | 8 | 0 | 0 | 1 | 1 | 1 | 1 | 1 | 13 |
| SS | 2 | 6 | 10 | 9 | 4 | 5 | 7 | 5 | 5 | 53 |
| Ct | 9 | 0 | 0 | 0 | 2 | 0 | 1 | 2 | 1 | 15 |
| Cr S | 2 | 1 | 1 | 0 | 0 | 0 | 1 | 7 | 1 | 13 |
| CL | 15 | 0 | 5 | 2 | 3 | 5 | 10 | 1 | 2 | 43 |
| VR | 1 | 0 | 0 | 0 | 2 | 0 | 0 | 0 | 0 | 3 |
| OTROS | | 2 | 1 | 0 | 1 | 0 | 0 | 2 | 2 | 8 |
| TOTAL | 30 | 21 | 17 | 12 | 15 | 15 | 20 | 22 | 15 | 167 |

TABLA II. RNA Y SUS VARIANTES ENCONTRADAS

| ART | CNN | ONN | PCNN | RNN | PRNN | RBF NN | SOM | OTRAS | MLP, BP |
|----------|-------|--------|----------------------------|--------------------------|---------------|--------------|-------|-----------------------|-------------------------|
| ART MMAP | DCNN | LEGION | ICM | Elman Jordan | PNN | Autoadaptiva | SOFM | Caóticas | |
| MARTMAP | SON | | PCNN multicanal | Lotka Volterra RNN | WPNN | FCM RBFNN | PSOM | Neurodifusas | MLP GMP |
| SFAM | TCNN | | Encadenamiento unitario | DCRNN | GMM | NeuroRBFNN | FCNN | TCAN | MLP pesos gaussianos |
| | PoCNN | | | RNNBP | RNA aleatoria | | SOTFN | TDNN | |
| | CTCNN | | | IO RNN | | | SASOM | FNN | |
| | | | | LSTM RNN | | | SOBS | Membrana excitable | |
| | | | | Hopfield | | | SOTM | | |

cantidades de artículos organizados por redes y tipo de procesamiento que se realiza en la imagen. La PCNN no se agregó en la Tabla I debido a que se tomó como base el estudio de Wang en [3], donde se documenta el potencial de la red y las aplicaciones a tareas de segmentación, reconocimiento de patrones y objetos. Tampoco se toma las SNN debido a que los trabajos analizados no reportan una red concreta. Se puede ver en la Tabla I que las aplicaciones más comunes son segmentación de formas y clasificación. Referente a segmentación de formas, las redes que reportaron más resultados fueron RBFNN, MLP con funciones de activación gaussianas, las ONN y las redes caóticas. Mientras que las redes que actúan más como clasificadoras son ART, PNN y RBFNN. La tercera forma de procesamiento más común es Ct, para lo cual fueron redes ART las más utilizadas aunque las RNN y la SOM reportaron trabajos. En segmentación de bordes, el modelo más utilizado en la literatura analizada fue CNN, mientras que en segmentación de color fue la SOM. Para segmentación de texturas el GMM, las redes aleatorias y PNN fueron los algoritmos más comunes. Un aspecto que se ve es que se reporta un resultado de eliminación de ruido, este se tomó como una categoría aparte por que fue la única aplicación en tareas e pre-procesamiento. Finalmente detección de movimiento aunque no generó muchos resultados, fue SOM y CNN los que reportaron trabajos con buenos resultados.

También se puede en la Tabla I ver que las redes con más resultados son ART, CNN y SOM. ART mostró más resultados para agrupamiento de datos y clasificación, CNN muestra más resultados para detección de bordes y segmentación de formas, mientras que SOM muestra más resultados para segmentación de

color. Además se puede observar también que CNN y SOM reportaron resultados en todas las formas de segmentación.

Dentro de las aplicaciones más comunes, resalta que se obtuvieron varios resultados en fueron procesamiento de imágenes médicas, sentido remoto, reconocimiento de caracteres y reconocimiento de placas de automóvil.

En la Tabla II se observa un resumen de las RNAs y modificaciones de redes que resultaron los modelos más exitosos reportados en el análisis de los 167 artículos y fueron descritos en la sección 3. En el caso de ART, sus variantes muestran que puede servir en tareas de segmentación de formas y objetos. Para CNN, las modificaciones fueron muy variadas en aplicaciones, ya que fueron útiles en tareas de detección de movimiento, texturas en imágenes medicas, segmentación de huella digital, formas y bordes. Además se presentan aplicaciones en hardware. Referente a LEGION, este fue un modelo documentado en varios trabajos de manera exitosa para segmentación de formas e implementaciones en hardware. Las modificaciones de la PCNN se enfocaron más en perfeccionar el modelo para procesamiento de imágenes y en el caso de la PCNN multicanal para aplicaciones de fusión de imágenes. Las redes recurrentes que se muestran en la Tabla II, tuvieron buenos resultados para aplicaciones específicas en movimiento y detección de objetos. El resto de las variantes de RNN obtuvieron buenos resultados en simulación. En el caso de las variantes de RBFNN, fue usual encontrarla con algoritmos genéticos y difusos para aplicaciones a reconocimiento de rostros y segmentación de imágenes del cerebro. Referente a los modelos de la categoría RPNN, se observó el marcado uso en segmentación y detección de texturas con GMM, además WPNN fue exitosa en segmentación de

imágenes del cerebro y PNN para detección de placas en automóviles. Para la SOM, las variantes SOMF, PSOM, SOFT NN, SASOM muestran muy Buenos resultados en procesamiento de color, mientras que SOBS, FCNN útiles para detección de movimiento.

V. CONCLUSIONES

De la revisión de los 167 artículos, se pudo observar que las RNAs tuvieron un uso muy marcado para tareas de segmentación. De manera más específica, son muy utilizadas para segmentación de formas, color, textura, movimiento y bordes.

De acuerdo al análisis de esta revisión de artículos, segmentación de forma fue la aplicación más común de varias arquitecturas de RNA, ya que es difícil extraer con métodos clásicos de procesamiento de imágenes formas irregulares que no tienen un patrón tan repetible, tales como tejidos biológicos, regiones en sensado remoto, patrones biométricos, inspección de producto, etc.

Referente a procesamiento de color, los mejores resultados en este análisis fueron SOFM, PSOM, SOFT NN, SASOM. Para textura en este análisis fue GMM y la SON. Para segmentación de movimiento SOBS, FCNN, DTCNN y la TDNN han sido los modelos más exitosos de acuerdo con la literatura analizada y segmentación de bordes ha sido más estudiado por varios modelos basados en la CNN. Para tareas de clasificación las redes ART, MLP, RBFNN y PNN han sido las más utilizadas.

La PCNN aunque no se documentó en este trabajo, se puede constatar mediante el estudio en [3] que es un modelo muy apto para segmentación de imágenes. Un detalle interesante es que la SOM ha sido documentada antes como un modelo muy flexible y en esta revisión resultó útil en todas las tareas de segmentación de imágenes. Otro detalle es que las ONN aparte de ser modelos exitosos para segmentación, también se documenta su flexibilidad en implementaciones en hardware. Además, CNN es documentada con una capacidad mayor que algoritmos clásicos en detección de bordes y segmentación de formas. En los últimos cuatro tipos de redes mencionados, se pudo observar su flexibilidad para hacer modificaciones y nuevos modelos, además de que generan resultados estables y consistentes en trabajos propuestos recientemente, por lo que se asume que se puede trabajar por varios años con estas redes. Sin embargo, durante la revisión de SNNs, se pudo notar que existen muchos laboratorios y universidades que aún proponen sus SNNs. La mayoría de las SNNs se basan en investigaciones recientes de los potenciales de acción del sistema nervioso, por lo que conforme vayan surgiendo nuevos conocimiento acerca del funcionamiento de la corteza visual, vendrán modelos de RNAs que funcionen de manera similar a la visión de los animales.

RECONOCIMIENTOS

Los autores agradecen al Fondo Mixto de Fomento a la Investigación Científica y Tecnológica CONACYT- Gobierno del Estado de Chihuahua, por el apoyo para realizar este trabajo bajo el apoyo CHIH-2009-C02-125358.

REFERENCIAS

- [1] Egmont-Petersen, Ridder, Handels, "Image processing with neural networks—a review", *Pattern recognition*, vol. 35, no. 10, pp. 2279-2301, Oct 2002.
- [2] Misra Janardan and Indranil Saha, "Artificial neural networks in hardware: A survey of two decades of progress", *Elsevier Neurocomputing*, vol. 74, no. 1, pp. 239-255, Dec 2010.
- [3] Zhaobin Wang, Yide Ma, Feiyan Cheng and Lizhen Yang; "Review of pulse-coupled neural network", *Elsivier Imagen and vision computer*, vol. 28, no. 1, pp. 5-13, Jan 2010.
- [4] Weihua and Yuhong Li, "Applications of Artificial Neural Networks in Financial Economics: A Survey", *IEEE Computational Intelligence and Design (ISCID)*, vol. 1, Oct. 2010, pp. 211-214.
- [5] Chowdhury, F.N, "A survey of neural networks applications in automatic control", *IEEE Proceedings of the 33rd Southeastern Symposium on System Theory*, Athens OH, Mar 2001, pp. 349-353.
- [6] Micheli and Tzanakou, "A Comparative Survey on Biometric Identity Authentication Techniques Based on Neural Networks", *IEEE Biometrics: Theory, Methods, and Applications book*, Nov 2010, pp. 47-79.
- [7] Naz Samina, Hammad Majed and Humayun Irshad, "Image Segmentation using Fuzzy Clustering: A Survey", *International Conference on Emerging Technologies; islamabad*, Oct 2010, pp. 181-186.
- [8] N Senthilkumaran and R. Rajesh, "Image Segmentation - A Survey of Soft Computing Approaches", *IEEE computer society, International Conference on Advances in Recent Technologies in Communication and Computing*, Oct 2009, pp. 844-846.
- [9] Lefteri H. Tsoukalas, Robert E. Uhrig, "Fuzzy and neural approaches in engineering", *Wiley & SONS INC*, 1997, pp. 191-227.
- [10] Robert Hecht-Nielsen, *Perceptrons*; University California San Diego, Institute for Neural Computation Technical Report No. 0403, Jul 2004.
- [11] S. Grossberg, "Competitive learning: from iterative activation to adaptive theory", *Cognitive science*, vol. 11, no. 1, pp. 23-63, Jan 1987.
- [12] Grossberg S and Carpenter G, "Adaptive Resonance Theory", *Cambridge, Massachusetts: The Handbook of Brain Theory and Neural Networks*, no. 2, (1-12), 1998.
- [13] Weiguo Liu, Karen C. Seto, Elaine Y. Wu, Sucharita Gopal, and Curtis E. Woodcock, "ART-MMAP: A Neural Network Approach to subpixel classification", *IEEE transactions on geoscience and remote sensing*, vol. 42, no. 9, pp. 1976-1983, Sep 2004.
- [14] Tan, Chue Pon, Chen Change Loy, Weng Kin Lai, Chee Peng Lim, "Robust modular ARTMAP for multi-class shape recognition", *IEEE World Congress on Computational Intelligence*, Jun 2008, pp. 2405-2412.
- [15] M Keyarsalan, GH A Montazer and K Kazemi, "Font-based persian character recognition using Simplified Fuzzy ARTMAP neural network improved by fuzzy sets and Particle Swarm Optimization", *IEEE, Evolutionary Computation Congress*, Trondheim, May 2009, pp. 3003-3009.
- [16] Makasakazu Kawahara, Takashi Inoue and Yoshifumi Nishio, "Image Processing Application Using CNN with Dynamic Template", *International Workshop on Cellular Nanoscale; Berkeley CA*, Feb 2010, pp. 1-6.
- [17] Michal Strzelecki, Joonwhoan Lee and Sung-Hwan Jeong, "Analysis of Biomedical Textured Images with Application of Synchronized Oscillator-based CNN", *IEEE 12th International Workshop on Cellular Nanoscale Networks and their Applications (CNNA)*, Berkeley CA, Feb 2010, pp. 1-6.
- [18] Hezekiah Babatunde, Olusegun Folorunso and Adio Akinwale, "A Cellular Neural Network- Based Model for Edge Detection", *Journal of Information and Computing Science*, vol. 5, no. 1, pp. 3-10, 2010.
- [19] Jiaying Kang and Wenjuan Zhang, "Fingerprint Segmentation using Cellular Neural Network", *IEEE International Conference on Computational Intelligence and Natural Computing*, vol. 2, no. 1, Jun 2009, pp. 11-14.
- [20] F Corinto, M Biey and M Gilli, "Non-linear coupled CNN models for multiscale image analysis", *International journal of circuit theory and applications*, vol. 34, no. 1, pp. 77-88, Jan 2006.
- [21] Koki Nishizono and Yoshifumi Nishio, "Image Processing of Gray Scale Images by Fuzzy Cellular Neural Network", *RISP International Workshop nonlinear circuits*, Honolulu Hawaii, USA, Mar 3-5 2006, pp. 90-93.
- [22] Fujita Tomohiro and Okamura Takashi, "CAM-Universal Machine: A DTCNN Implementation for Real-Time Image Processing", *11th International Workshop on Cellular Neural Networks and their Applications*, Santiago de Compostela, Spain, pp. 219-223, Jul 2008.
- [23] Ryanne Dolan, Guilherme DeSouza, "GPU-Based Simulation of Cellular Neural Networks for Image Processing", *Proceedings of International Joint*

- Conference on Neural Networks, Atlanta Georgia, USA, Jun 2009, pp. 730-735.
- [24] Pramod L. Narasimha, Walter H. Delashmit, Michael T. Manry, "An integrated growing-pruning method for feedforward network training", *Science Direct, Neurocomputing*, vol. 71, no. 13-15, Aug 2008, Pages 2831-2847.
 - [25] Crespo Juan, Duro Richard and Lopez Fernando, "Gaussian Synapse ANNs in Multi- and Hyperspectral Image Data Analysis", *IEEE transactions on instrumentation and measurement*, vol. 52, no. 3, pp. 724-732, Jun 2003.
 - [26] Mohd Shiblee, B Chandra, Prem K Kalra, "Generalized Power Mean Neuron Model", *IEEE, Third International Conference on Knowledge Discovery and Data Mining*, Jan 2010, pp. 276-279.
 - [27] G K Rajini and Dr Ramachandra Reddy, "Performance Evaluation of Neural Networks for Shape Identification in Image Processing", *IEEE computer society, International Conference on Signal Acquisition and Processing*, Bangalore, India, 2010, pp. 255-258.
 - [28] Naeem Shareef, DeLiang L. Wang and Roni Yagel, "Segmentation of Medical Images Using LEGION", *IEEE transactions on medical imaging*, vol. 18, no. 1, pp. 74-91, Jan 1999.
 - [29] Denis Fernandes, Jeferson Polidoro Stedile and Philippe Olivier Alexandre Navaux, "Architecture of Oscillatory Neural Network for Image Segmentation", *IEEE computer society, Symposium on Computer Architecture and High Performance Computing*, 2002, pp. 29-36.
 - [30] Daniel Fernández, Gerard Villar, Eva Vidal, Eduard Alarcón, Jordi Cosp and Jordi Madrenas, "Mismatch-tolerant cmos oscillator and excitatory synapse for bioinspired image segmentation", *IEEE International Symposium, Circuits and Systems, ISCAS*, May 2005, pp. 4114-4117.
 - [31] Arpitan Chatterjee, Kanay Ch Paul and Bipan Tudu, "Application of recurrent neural network for generating grayscale digital half-tone images", *IEEE computer society, International Conference on Emerging Applications of Information Technology*, Feb 2011, pp. 41-44.
 - [32] Bochuan Zheng, Zhan Yi, "Extracting Long Contour by Using the Competitive Layer Model of the Lotka-Volterra Recurrent Neural Networks", *IEEE International Conference on Advanced Computer Theory and Engineering*, vol. 3, Aug 2010, pp. 627-631.
 - [33] Wei Zhou and Jacek Zurada, "Discrete-time Recurrent Neural Networks for Medical Image Segmentation based on Competitive Layer Model with LT neurons", *IEEE Biomedical Engineering and Computer Science international conference*, April 2010, pp. 1-4.
 - [34] Guanzhong Li, "A New Dynamic Strategy of recurrent neural network", *IEEE proceedings Cognitive Informatics international conference*, Kowloon, Hong Kong, Jun 2009, pp. 486-491.
 - [35] Shun Nishide, Tetsuya Ogata, Ryunosuke Yokoya, Jun Tani, Kazunori Komatani, and Hiroshi G. Okuno, "Active Sensing based Dynamical Object Feature Extraction", *IEEE International Conference on Intelligent Robots and Systems*, Nice Francia, Sep 2008, pp. 1-7.
 - [36] Monica Bianchini, Marco Maggini and Lorenzo Sarti, "Object localization using Input/Output Recursive Neural Network", *IEEE Computer society international conference Pattern Recognition*, vol. 3, Sep 2006, pp. 1-4.
 - [37] Reiter Stephan, Björn Schuller and Gerhard Rigoll, "A combined LSTM-RNN - HMM - approach for meeting event segmentation and recognition", *IEEE proceedings, International conference on Speech and Signal Processing, Acoustics*, May 2006, vol. 2, pp. 393-396.
 - [38] Hirotoku Morikawu and Shigeo Wudu, "Scene discrimination by recalling with visual neural system", *IEEE International Conference on Neural & Signal*, Nangng China, Dec 2003, pp. 200-203.
 - [39] Veera Ms B, "Research Study of Neural Networks for image categorization and retrieval", *IEEE Computer and Automation Engineering International Conference*, Singapore, vol. 2, Feb 2010, pp. 686-690.
 - [40] S Sathish Kumar, M. Moorthi, M Madhu, Dr R Amutha, "An improved method of segmentation using fuzzy-neuro logic", *IEEE computer society Second International Conference on Computer Research and Development*, May 2010, pp. 671-675.
 - [41] K. Sing, D. K. Basu. M. Nasipuri, and M. Kundu, "Self-adaptive RBF neural network-based segmentation of medical images of the brain", *IEEE Proceedings Intelligent Sensing and Information conference*, Jan 2005, pp. 447-452.
 - [42] Benamrane Nacéra and Abdelkader Fekir, "Medical Images Segmentation By Neuro-Genetic Approach", *IEEE computer society, International Conference on Information Visualisation*, Jul 2005, pp. 981-986.
 - [43] Rivas-Perea P, J. G. Rosiles, M. I. Chacon M, "Traditional and Neural Probabilistic Multispectral Image Processing for the Dust Aerosol Detection Problem", *IEEE Southwest Symposium Image Analysis & Interpretation (SSIAI)*, 23-25 May 2010, pp. 169 – 172.
 - [44] Tao Song, Mo Jamshidi, Roland R. Lee and Mingxiong Huang, "A Novel Weighted Probabilistic Neural Network for MR Image Segmentation", *IEEE International Conference on Systems, Man and Cybernetics*, vol. 3, Oct 2005, pp. 2501-2506.
 - [45] Tao Song, M. Jamshidi, Roland R. Lee and Mingxiong Huang, "A Modified Probabilistic Neural Network for Partial Volume Segmentation in Brain MR Image", *IEEE Transactions On Neural Networks*, vol. 18, no. 5, pp. 1424-1432, Sep 2007.
 - [46] Culibrk Dubravko, Oge Marques and Daniel Socek, "Neural Network Approach to Background Modeling for Video Object Segmentation", *IEEE Transactions On Neural Networks*, vol. 18, no. 6, pp. 1614-1627, Nov 2007.
 - [47] Rong Lu and Yi Shen, "Image Segmentation Based on Random Neural and Gabor filters", *IEEE Engineering in Medicine and Biology 27th Annual Conference*, pp. 6464- 6467, Jan 2006.
 - [48] Reynolds, Douglas, "Gaussian mixture Model", Massachusetts, MIT Lincoln Laboratory, Disponible: www.ll.mit.edu/mission/.../list/.../0802_Reynolds_Biometrics-GMM.pdf
 - [49] Faiza Mekhalfa, Nafaâ Nacereddine and Aïcha Baya, "Unsupervised Algorithm for Radiographic Image Segmentation Based on the Gaussian Mixture Model", *International Conference Eurocon 2007*, Warsaw, Sep 2007, pp. 289-293.
 - [50] Oliver Le Meur and Jean-Claude Chevet, "Relevance of a Feed-Forward Model of Visual Attention for Goal-Oriented and Free-Viewing Tasks", *IEEE Transactions On Image Processing*, vol. 19, no. 11, pp. 2801–2813, Nov 2010.
 - [51] K Blekas, "A Spatially Constrained Mixture Model for Image Segmentation", *IEEE Transactions On Neural Networks*, vol. 16, No. 4, pp. 494–498, April 2007.
 - [52] Antonio Peñalver, Francisco Escolano and Juan Sáenz, "Learning Gaussian Mixture Models With Entropy-Based Criteria", *IEEE Transactions On Neural Networks*, vol. 20, no. 11, pp. 1756-1771, Nov 2009.
 - [53] M.N.M. Sap, Ehsan Mohebi, "Hybrid Self Organizing Map for Overlapping Clusters", *International Journal of Signal Processing, Image Processing and Pattern Recognition*, pp. 11-20, 2008.
 - [54] Teuvo Kohonen, Samuel Kaski, Krista Lagus, Jarkko Salojärvi, Jukka Honkela, Vesa Paatero, and Antti Saarela, "Self Organization of a Massive Document Collection", *IEEE Transactions on Neural Networks*, vol. 11, no. 3, pp. 574-585, May 2000.
 - [55] Jun Zhang and Qieshi Zhang, "Color Image Segmentation Based on Wavelet Transformation and SOFM Neural Network", *IEEE Proceedings of International Conference on Robotics and Biomimetics*, Dec 2007, pp. 1778-1781.
 - [56] Christodoulos I. Christodoulou, Silas C. Michaelides, and Constantinos S. Pattichis, "Multifeature Texture Analysis for the Classification of Clouds in Satellite Imagery", *IEEE transactions on geoscience and remote sensing*, vol. 41, no. 11, pp. 2662–2668, Nov. 2003.
 - [57] Claudia Nölker and Helge Ritter, "Visual Recognition of Continuous Hand Postures", *IEEE Transactions On Neural Networks*, vol. 13, no. 4, pp. 983–994, Jul 2002.
 - [58] Ying Wu and Thomas Huang, "Nonstationary Color Tracking for Vision-Based Human-Computer Interaction", *IEEE transactions on neural networks*, vol. 13, no. 4, pp. 948–960, Jul 2002.
 - [59] Lucia Maddalena and Alfredo Petrosino, "A Self-Organizing Approach to Background Subtraction for Visual Surveillance Applications", *IEEE Transactions On Image Processing*, vol. 17, no. 7, pp. 1168-1177, Jul 2008.
 - [60] Matthew Kyan, Kambiz Jarrah, Paisarn Muneesawang and Ling Guan, "Strategies for Unsupervised Multimedia Processing: self-organizing trees and forests", *IEEE computational intelligence magazine*, vol. 1, no. 2, pp. 27- 40, May 2006.
 - [61] Mohamed Salah Salhi, Najet Arous, and Nouredine Ellouze, "Principal temporal extensions of SOM: Overview", *International Journal of Signal Processing, Image Processing and Pattern Recognition*, vol. 2, no. 4, pp. 61-84, Dec. 2009.
 - [62] Mohamad Awad, Kacem Chehdi, and Ahmad Nasri, "Multicomponent Image Segmentation Using a genetic algorithm and artificial neural network", *IEEE Geoscience and remote sensing letters*, vol. 4, no. 4, pp. 571–575, Oct. 2007.
 - [63] Xiaou Tang, Xinbo Gao, Jianzhuang Liu and Hongjiang Zhang, "A Spatial-Temporal Approach for Video Caption Detection and Recognition", *IEEE Transactions Neural Networks*, vol. 13, no. 4, pp. 96–971, Jul 2002.

- [64] Chia-Feng Juang, Shih-Hsuan Chiu, and Shu-Wew Chang, "A Self-Organizing TS-Type Fuzzy Network With Support Vector Learning and its Application to Classification Problems", *IEEE Transactions on Fuzzy Systems*, vol. 15, no. 5, pp. 998–1008, Oct 2007.
- [65] Laurent Perrinet, Manuel Samuelides, and Simon Thorpe, "Coding Static Natural Images Using Spiking Event Times: Do Neurons Cooperate?", *IEEE Transactions on Neural Networks*, vol. 15, no. 5, pp. 1164–1175, Sep 2004.
- [66] Peter Dayan and L.F. Abbott, "Theoretical Neuroscience", MIT Press, 2009 pp. 1-15.
- [67] N.G. Pavlidis, D.K. Tasoulis, V.P. Plagianakos, and M.N. Vrahatis, "Spiking Neural Network Training Using Evolutionary Algorithms", *IEEE Proceedings International Joint Conference on Neural networks*, 2005, 2190-2194 vol. 4.
- [68] Eugene M. Izhikevich, "Simple Model of Spiking Neuron", *IEEE Transactions on Neural Networks*, vol. 14, no. 16, pp. 1569-1572, Sep 2004.
- [69] Waldemar Swiercz, Krzysztof J. Cios, Kevin Staley, Lukasz Kurgan, Frank Accurso, and Scott Sagel, "A New Synaptic Plasticity Rule for Networks of Spiking Neurons", *IEEE Transactions on Neural Networks*, vol. 17, no. 1, pp. 94-105, Jan 2006.
- [70] QingXiang Wu, T.M. McGinnity, Liam Maguire and Jianyong Cai, "Detection of Straight Lines Using a Spiking Neural Network Model", *Fifth International Conference on Natural Computation*, 2009, pp. 385-389.
- [71] Mohammad A. Bhuiyan, Rommel Jalasutram, and Tarek M. Taha, "Character recognition with two spiking neural network models on multicore architectures" *IEEE Symposium on Computational Intelligence for Multimedia Signal and Vision Processing*, 2009, pp. 29-34.
- [72] KangWoo Lee, Hilary Buxton, and Jianfeng Feng, "Cue-Guided Search: A Computational Model of Selective Attention", *IEEE Transactions on Neural Networks*, vol. 16, no. 4, pp. 910-924, July 2005
- [73] Liang Zaho and Elbert Macau, "A Network of Dynamically Coupled Chaotic Maps for Scene Segmentation", *IEEE Transactions On Neural Networks*, vol. 12, no. 6, pp. 1375–1385, Nov 2001.
- [74] Liang Zhao Andre C. P. L. F. de Carvalho, and Zhaohui Li, "Pixel Clustering by Adaptive Pixel Moving and Chaotic Synchronization", *IEEE Transactions On Neural Networks*, vol. 15, no. 5, pp. 1176–1185, Sep 2004.
- [75] Raymond T S Lee, "Transient-Chaotic Autoassociative Network (TCAN) Based on Lee Oscillators", *IEEE Transactions On Neural Networks*, vol. 15; no. 5, pp. 1228–1243, Sep 2004.
- [76] Shan Shen, William Sandham, Malcolm Granat, and Annette Sterr, "MRI Fuzzy Segmentation of Brain Tissue Using Neighborhood Attraction With Neural-Network Optimization", *IEEE Transactions on Information Technology in Biomedicine*, vol. 9, no. 3, pp. 459–467, Sep 2005.
- [77] Chin_teng Lin, Wen-Chang and Sheng-Fu Liang, "An On-Line ICA-Mixture-Model-Based Self-Constructing Fuzzy Neural Network", *IEEE Transactions On Circuits And Systems*, vol. 52, no. 1, pp. 207–221, Jan 2005.
- [78] Christoph Rashe, "Neuromorphic Excitable Maps for Visual Processing", *IEEE Transactions On Neural Networks*, vol. 18, no. 2, pp. 520–529, Mar 2007.
- [79] Max Mignotte, "MDS-Based Multiresolution Nonlinear Dimensionality Reduction Model for Color Image Segmentation", *IEEE Transactions On Neural Networks*, vol. 22, no. 3, pp. 447-460, Mar 2011.

- [80] Chia Feng Juang, Shih-Hsuan Chiu and Shen-Jie Shiu; "Fuzzy System Learned Through Fuzzy Clustering and Support Vector Machine for Human Skin Color Segmentation"; *IEEE Transactions On Systems Man And Cybernetics*, vol. 37, no. 6, pp. 1077–1087, Nov 2007.
- [81] Chia Feng Juang, Chia-Ming Chang, "Human Body Posture Classification by a Neural Fuzzy Network and Home Care System Application", *IEEE Transactions On Systems Man And Cybernetics*, vol. 37, no. 6, pp. 984–994, Nov 2007.
- [82] Ming Hsuan Yang, Narendra Ahuja and Mark Tabb; "Extraction of 2D Motion Trajectories and Its Application to Hand Gesture Recognition", *IEEE Transactions On Pattern Analysis And Machine Intelligence*, vol. 24, no. 8, pp. 106-1074, Aug 2002.



Juan A. Ramírez-Quintana nació en Chihuahua Chih. México en 1981. Recibió el grado de Licenciatura (2004) y Maestro en Ciencias (2007) en Ingeniería Electrónica por el Instituto Tecnológico de Chihuahua.

Desde el 2008 hasta el 2011 fue profesor en el Instituto Tecnológico de Chihuahua. Actualmente es estudiante de doctorado en el Instituto Tecnológico de Chihuahua. Sus áreas de interés son visión por computadora, procesamiento digital de imágenes, percepción visual e inteligencia computacional.

El M.C. Ramírez es miembro estudiante de la IEEE.



Mario I. Chacón Murguía nació en la ciudad de Chihuahua en 1959. Recibió los grados de ingeniería (1982) y M.C. (1985) en ingeniería electrónica del Instituto Tecnológico de Chihuahua y el grado de Ph.D. (1998) de New México State University, Las Cruces NM, USA.

Su experiencia profesional incluye puestos como Asistente de Investigador y Asistente de Profesor en New México State University. Ha desarrollado proyectos de investigación para varias compañías.

Actualmente es Profesor - Investigador en el Instituto Tecnológico de Chihuahua, Chihuahua, Chih., México donde es director de los laboratorios de DSP y Visión y Percepción Visual con aplicaciones en Robótica.

El Dr. Chacón es miembro del Sistema Nacional de Investigadores. Ha publicado más de 105 trabajos en revistas internacionales, nacionales y congresos, así como la publicación de dos libros. Su investigación actual incluye percepción visual, visión por computadora, procesamiento de imágenes y señales usando inteligencia computacional y reconocimiento de patrones.